Relatório Técnico: Limites Arquiteturais e Estabilização

Este documento registra os testes de carga, gargalos estruturais descobertos e as configurações de mitigação aplicadas no servidor OpenArena (motor ioquake3) durante o experimento de injeção senoidal de bots para o Trabalho de Conclusão de Curso (TCC). O objetivo da infraestrutura era suportar alta carga de bots simultâneos controlados por uma VM externa, exportando as métricas de estresse para o Grafana.

1. O Problema: Colapso do Servidor sob Alta Carga

Durante os testes de injeção de alta carga (acima de 20 bots), o contêiner Docker (VM1) apresentava os seguintes comportamentos de falha:

- Ignorar silenciosamente a entrada de novos bots a partir da marca de 17 ou 18 entidades.
- Desligamento súbito (*crash* silencioso) na marca exata de 25-26 bots no mapa.
- Falha fatal ao tentar iniciar o contêiner após tentativas de alocar grandes blocos de memória RAM.

A investigação revelou que o problema não era falta de recursos na Máquina Virtual host (que possuía 2 vCPUs e 2GB de RAM, utilizando apenas 24% de sua capacidade), mas sim **limitações estruturais severas da arquitetura de 32-bits do motor original do jogo**.

2. Gargalos Arquiteturais Mapeados

2.1. Limite da Memória Principal (`com_hunkMegs`)

A *Hunk Memory* aloca a geometria do mapa, texturas e os modelos 3D dos personagens (skins).

- **Limite Físico Descoberto:** 512 MB.
- **Problema:** O motor não suporta blocos maiores que isso devido às restrições do alocador dinâmico em C (arquitetura 32-bits). Ao tentar injetar bots variados, o servidor lotava essa memória rapidamente, rejeitando novas conexões.
- **Solução Aplicada:** Restrição do script para injetar apenas cópias do modelo `"sarge"`. O motor carrega a malha 3D na Hunk Memory apenas uma vez, economizando RAM estática suficiente para dezenas de clones.

2.2. Limite da Memória de Inteligência Artificial (`com_zoneMegs`)

A *Zone Memory* é onde o motor armazena dados dinâmicos e o AAS (*Area Awareness System*), a malha invisível de rotas que os bots utilizam para locomoção e tomada de decisão.

- **Limite Físico Descoberto:** 128 MB (o padrão de fábrica costuma ser 24 MB).
- **Problema:** Ao tentar expandir a memória para 256 MB, o servidor não iniciou, emitindo um erro fatal (`Z_Malloc Error`). O limite máximo seguro que o motor consegue alocar em um bloco contínuo é 128 MB.

2.3. Gargalo de Processamento (Single-Thread)

Esta foi a restrição mais crítica para a escalabilidade, causando os colapsos entre 25 e 26 bots.

- **Limite do Código-Fonte:** O limite de conexões é formalmente de 64 clientes (`sv_maxclients 64`). No entanto, todo o processamento de inteligência artificial da *botlib* é executado em **um único núcleo de processador (Single-Thread)**.
- **O Colapso:** Acima de 25 bots calculando rotas simultaneamente a cada milissegundo, a thread única da CPU esgota sua janela de tempo de processamento. O servidor sofre *timeout* nos pacotes UDP da rede, resultando na queda do serviço.

3. Estratégias de Mitigação Implementadas

Para extrair o desempenho máximo do servidor e atingir o estresse ideal para coleta de métricas no Grafana, as seguintes defesas foram configuradas:

- **Rampa de Aquecimento (Warm-up):** Injeção inicial compassada de 1 bot por segundo. Isso previne o estrangulamento da CPU e a consequente perda de pacotes UDP na fase inicial da senoide.
- **Prevenção de Falha de Segmentação:** Adequação da sintaxe RCON (`addbot sarge 4 free 0 bot_X`) para evitar que o motor tentasse processar *strings* vazias, o que causava corrupção de memória.
- **Alívio da CPU (`bot_nochat 1`):** Desativação do chat da IA para poupar ciclos de processamento de consultas aos bancos de personalidade, priorizando 100% do cálculo para as rotas físicas (AAS).

4. Configuração Final Estável

O parâmetro de inicialização otimizado aplicado no `docker-compose.yml`, forçando a infraestrutura aos seus limites físicos seguros:

```
command: /usr/games/openarena-server +set com_hunkMegs 512 +set com_zoneMegs
128 +set sv_maxclients 64 +set dedicated 1 +set net_port 27960 +exec server.cfg
```

5. Conclusão Acadêmica

A investigação comprovou empiricamente que o teto de escalabilidade de um servidor baseado na id Tech 3 não é imposto pela quantidade total de memória RAM da máquina virtual host, nem pelo limite teórico de clientes configurado pelo administrador. O gargalo primário e instransponível reside na arquitetura **Single-Thread** do processamento da inteligência artificial acoplada à limitação de alocação estática de memória de 32-bits.

Manter a infraestrutura oscilando cargas próximas a 30 bots representa o cenário de estresse máximo e contínuo para este motor (100% de ocupação da *thread* principal), fornecendo uma base perfeitamente fundamentada para a coleta e análise de métricas no escopo deste TCC.